

Master Data Science: Entregable 1

Contexto:

El objetivo de este dataset es predecir el precio del vehículo, para ello en este primer entregable se necesitará realizar todo el data cleaning y data preprocessing de los datos (ojo que si bien el objetivo es predecir el precio no será necesario hacer la predicción)

El dataset se ha enviado por slack (pendiente de subirlo a una carpeta en el campus)

El trabajo es grupal

joaquinpeticari@gmail.com [Cambiar de cuenta](#)



Borrador guardado

El nombre, el correo y la foto asociados a tu cuenta de Google se registrarán cuando subas archivos y envíes este formulario

*** Indica que la pregunta es obligatoria**

Correo *

joaquinpeticari@gmail.com

Nombres y Apellidos

12-dscesp-0925-grupo-6



1. ¿Qué columnas eliminaron inicialmente del dataset y por qué?

Se eliminaron las columnas de marca y asientos_traseros_plegables, porque todo el dataset es de BMW y porque había demasiados nulos (70.02%) respectivamente.

2. Manejo de nulos, explicar qué se hizo con los nulos por cada columna

Los nulos en precio se eliminaron al tratarse de la columna target. Los de color se rellenaron con 'desconocido' al tratarse de una variable poco relevante. Luego se pasó al dataset por un filtro knn diseñado por nosotros que se encargaba de agrupar por variables que habían sido separadas entre equipamiento, estructurales y fechas, de modo que para rellenar en una primera pasada los equipamientos agrupábamos por estructurales, rangos de km y potencia, y escogíamos por moda con una dominancia de 70%. Luego rellenábamos estructurales. Hacíamos una segunda pasada menos estricta con una dominancia simple del 50% y al rellenar ya casi el 80% de los nulos empezábamos a rellenar los nulos de fecha de registro (50%) usando la mediana con un 75% de dominancia. Tras unas pasadas más con filtros menos estrictos rellenábamos los nulos de equipamiento con False y borrábamos las filas donde teníamos más de un nulo.

3. Análisis univariable, explicar alguna información interesante encontrada

En km tenemos un caso con kilómetros negativos que rellenamos con la mediana para ese modelo, un caso con 1 millón de km que borramos. En potencia teníamos casos con potencia por debajo de 50 CV que decidimos volver nulos y volver a pasar por el filtro de vecindad (knn). En precio vimos también unos errores, seguramente erratas, que eran unos suv con precios demasiado altos que decidimos eliminar. Había precios por debajo de 1000€ que consideramos que eran chatarra para conseguir piezas, se podrían borrar pero los dejamos a falta de saber la finalidad del modelo a entrenar. El precio para el máximo es casi 12 veces la media, y el mínimo es 15.000 veces más bajo. En modelos vimos otra errata, un 'Active Tourer' que le faltaba el modelo y solo tenía el equipamiento, sesgando por sus otros datos dedujimos que se trataba de un '218 Active Tourer'. Tipos de coche entendimos que los van se referían a monovolumen entonces los Tourer justificaban esa cantidad. Otra cosa que nos llamó la atención porque nos hizo gracia es que era inversamente probable tener gps a tener elevalunas_electrico, lo que significa que podía tener GPS pero subir tu ventanilla con manivela a gusto. En tipo_gasolina había una errata con diesel que aparecía en algunos casos como Diesel, que corregimos pasando todas a lowercase. También, en un modelo X3 detectamos un fallo donde lo consideraba una van cuando se trata de un suv, que también modificamos a mano.



4. Análisis de correlación inicial, ¿Hay alguna variable correlacionada?

Había cierta correlación con algunos equipamientos como alerta_lim_velocidad, volante_regulable, aire_acondicionado, pero la mayor correlación la presentaban los km, la potencia y la antigüedad. Sin embargo, si hacíamos una correlación con spearman veíamos con los modelos una gran correlación con tipo_coche pero no con tipo_gasolina. Sin embargo, sospechamos e hicimos una correlación de V Cramer para estar seguros y vimos que también presentaba una correlación que spearman había pasado por alto convirtiendo un -0.04 en un 0.62

5. Análisis variable vs target, ¿Hay algún insight interesante?

Tendencias logarítmicas en km(negativa -43%), potencia(positiva+67%) y antigüedad(negativa -42%) muy clara. Algunos modelos tendían a ser más caros como el M4, M3 y X6 M. Los híbridos son más caros. Los suv, coupe y convertibles destacaban también por ser más caros. Los colores ninguno destacaban.

6. Transformación de categóricas a numéricas, ¿Qué variables van a transformar? ¿Que técnica se va usar?

Usamos OHE para convertir tipo_coche, tipo_gasolina, color y modelo. Para modelo planteamos usar CatBoost pero ya estaría correlacionada con el target así que os pareció incorrecto. Por otra parte, usar Ordinal Encoding nos hacía perder mucho la correlación así que también la descartamos

7. Escalar variables (usando minmaxscaler) y luego aplicar la correlación final de variables ¿Hay alguna variable finalmente correlacionada?

A parte de las mencionadas antes aparecieron correlaciones con tipo_coche para estate bajando el precio y suv subiéndolo hasta un 33%. Para tipo_coche aparecieron las características de cada tipo_coche que son el modelo 318 en los estate como barato, y los modelos X5 y X6 como caros.



8. Subir un pantallazo con el nombre de TODAS las columnas que tiene el dataframe final final vfin y el tipo de dato que tiene, tip lo más sencillo es hacer un .info al dataframe y tomarle un pantallazo y subirlo, importante deben aparecer TODAS las columnas

Sube 1 archivo compatible: image. Tamaño máximo: 10 MB.



FinalColumnas.p... X

9. Exportar en un excel de las primeras 50 filas del dataset (df.to_excel(...))

Sube 1 archivo compatible: spreadsheet. Tamaño máximo: 10 MB.



bmw.xlsx X

10. Sube el programa (el archivo .ipynb, NO EL PICKLE de lo contrario me quedaré sin espacio...) y con esto hemos terminado ;)

Sube 1 archivo compatible. Tamaño máximo: 10 MB.



bmw.ipynb X

Enviar

Borrar formulario

Nunca envíes contraseñas a través de Formularios de Google.

Este contenido no ha sido creado ni aprobado por Google. - [Contactar con el propietario del formulario](#) - [Términos del Servicio](#) - [Política de Privacidad](#)

¿Parece sospechoso este formulario? [Informe](#)

Google Formularios



