



Entregable 2

Supervised Machine Learning

El objetivo de este ejercicio es estimar la probabilidad de que una máquina con Sistema Operativo Windows se vea infectada por algún tipo de malware, en base a las distintas propiedades de la máquina.

Los datos para este ejercicio se encuentran en la siguiente URL:

https://www.dropbox.com/s/sxl5bpi2620p496/sample_mmp.csv

Se han obtenido muestreando el dataset original de la competición de [Kaggle Microsoft Malware Prediction](#), y se basan en las características obtenidas en la solución de endpoint Windows Defender. Cada fila del dataset corresponde a una máquina única, identificada por el campo MachineIdentifier. El target es la variable HasDetections, que indica que se ha detectado Malware en la máquina.

Se solicita:

1. Desarrollar el ML Canvas para este problema, suponiendo que nuestro modelo se usará para implementarlo en la aplicación Windows Defender dando aviso al usuario cuando su máquina supere un cierto umbral de probabilidad de ser infectada.
2. Desarrollar un Notebook con nuestra propuesta de modelo para resolver el problema. El Notebook debe contener todas las etapas de la ML Checklist debidamente comentadas (se valorará la claridad), y ejecutar sin problemas para obtener el modelo resultado. En concreto, debe realizarse la exploración de datos (se valorará el desarrollo de visualizaciones interesantes), el preprocesamiento, el modelado mediante un Decision Tree (opcionalmente, explorar otros algoritmos) y la evaluación.

¿En qué debo centrar mis esfuerzos para conseguir un buen proyecto?

Corrección

- Detectar la tarea correctamente
- Uso adecuado de algoritmo / algoritmos
- Transformación de variables distintas
- Partición correcta del dataset



- Métricas de evaluación adecuadas
- Conclusiones acuradas

Automatización

- Uso de funciones en Python
- Eficiencia del código: evitar for loops si es posible

Explicabilidad

- Visualizaciones chulas
- Plots variados
- Razonamiento de negocio
- Diferentes formas de explicar el resultado del modelo